



FUNDAÇÃO EDSON QUEIROZ UNIVERSIDADE DE FORTALEZA – UNIFOR
MBA EM CIENCIA DE DADOS DISCIPLINA DE
MICROSOFT AZURE MACHINE LERNING

Do Zero à Produção: Como Criar e Implantar
Modelos de ML no Azure Machine Learning

Alunos: Thiago Pinto Pereira – 2325857

George Rodrigue Bento – 2328540

Lucas Costa Ximenes Rodrigues - 2328743

1. INTRODUÇÃO

Com a quantidade de dados crescendo a cada dia, torna-se essencial usar ferramentas que ajudem a entender esses dados e tomar boas decisões. O aprendizado de máquina, parte da inteligência artificial, é uma dessas ferramentas – ele ajuda a encontrar padrões e resolver problemas de forma automática.

O Azure Machine Learning é uma plataforma fácil de usar que permite criar e colocar modelos de aprendizado de máquina em produção. Sua interface visual e recursos variados facilitam o trabalho tanto para iniciantes quanto para usuários mais experientes.

Este guia mostra, de forma simples e prática, como criar e implantar modelos no Azure Machine Learning usando o ML Automatizado. Vamos seguir um passo a passo, desde a preparação do ambiente até a apresentação dos resultados.


2. DESENVOLVIMENTO

Durante o desenvolvimento deste projeto, utilizamos uma conta criada por meio da página oficial do Azure for Students: <https://azure.microsoft.com/pt-br/free/students>

Essa iniciativa da Microsoft oferece, gratuitamente, um crédito de 100 dólares para uso acadêmico, permitindo que estudantes testem e explorem os recursos da plataforma Azure sem custos adicionais. Esse benefício foi fundamental para experimentar o Azure Machine Learning Studio de forma completa e prática. Esse benefício foi vinculado a conta de e-mail do aluno Unifor para ser aprovada.

Figura 1 - Acesso ao Azure Machine Learning

Na barra de pesquisa, a expressão "Machine Learning" foi inserida, resultando na exibição do serviço entre as opções de recursos disponíveis.




Fonte: Elaborada pelo autor

Figura 2 – Criando WorkSpace para construção do ambiente

O primeiro passo para começar a usar o Azure Machine Learning é criar um Workspace, que funciona como o ambiente principal para desenvolvimento e gerenciamento dos seus projetos de machine learning.


Em seguida, preencha as configurações básicas, como a assinatura (Subscription), o grupo de recursos (Resource Group) – que pode ser um novo ou um já existente –, o nome do Workspace e a região (Region), preferencialmente a mais próxima ou recomendada. Após inserir todas as informações, clique em "Review + Create" e depois em "Create" para concluir a criação do ambiente.



Fonte: Elaborada pelo autor

Figura 3: Implantação do workspace em andamento no Azure Machine Learning


A figura mostra a tela de verificação da criação de um novo workspace no Microsoft Machine Learning Service (Azure ML Studio). A mensagem "A implantação está em andamento" indica que o ambiente ainda está sendo criado. Nessa etapa, é possível acompanhar o status da operação, incluindo o nome da implantação, o grupo de recursos e o tempo estimado para conclusão.



Fonte: Elaborada pelo autor

Figura 4: Acesso ao Azure Machine Learning através da URL fornecida

A figura exibe a interface do workspace chamado "ws-diabetics" no portal do Azure. Um dos destaques é a URL do Azure Machine Learning Studio, que oferece acesso direto à plataforma dedicada ao desenvolvimento de modelos de machine learning. Ao clicar nesse link, o usuário é redirecionado para a interface principal do estúdio, onde pode iniciar seus projetos e configurar o ambiente de trabalho conforme suas necessidades.




Fonte: Elaborada pelo autor

Figura 5: Configurando uma instância de computação no Azure Machine Learning

Após acessar o Azure Machine Learning Studio, é necessário criar uma instância de computação para executar experimentos, treinar modelos e processar dados.

Para isso, acesse o menu "Instâncias de computação" dentro da seção "Computação" e clique em "Criar". Em seguida, defina as configurações principais, como o nome da instância, o tipo de máquina virtual e a região. Recomenda-se escolher um tipo de máquina compatível com os requisitos do projeto e com o orçamento disponível (no caso do plano educacional, opte por instâncias menores).

Após a criação, a instância poderá ser iniciada e estará pronta para uso em notebooks, pipelines e demais atividades de machine learning.

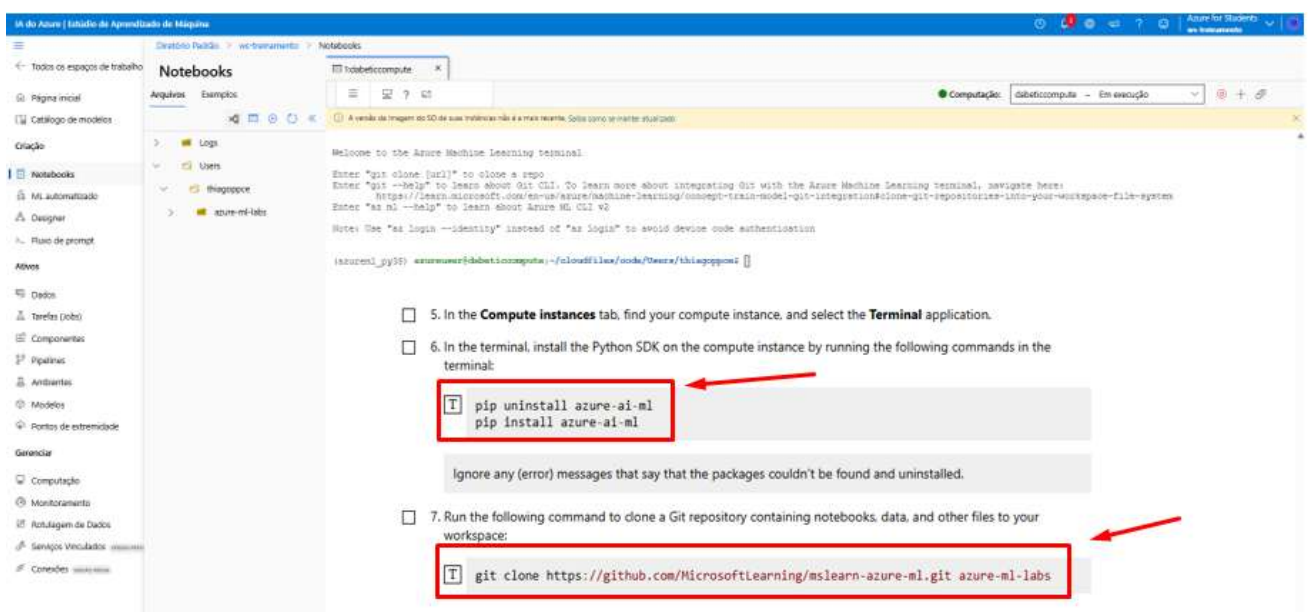


Fonte: Elaborada pelo autor

Figura 6: Instalando a base de dados usando o git clone no Azure Machine Learning na sessão notebook terminal

No Azure Machine Learning, acesse seu notebook e abra o terminal por meio da opção disponível no menu superior.

Dentro do terminal, você pode instalar o pacote necessário para interações com os serviços do Azure usando o seguinte comando: `pip install azure-ai-ml`. Após a instalação, utilize o comando `git clone` para baixar a base de dados a partir de um repositório Git.




Fonte: Elaborada pelo autor

Figura 7: Acesso à funcionalidade de ML Automatizado

Para acessar a funcionalidade de ML Automatizado no Azure Machine Learning Studio, no menu lateral, selecione a opção " ML Automatizado ". Em seguida, clique em " Novo trabalho de ML Automatizado " para iniciar um novo experimento. Escolha o dataset que será utilizado — você pode selecionar um já existente ou fazer o upload de um novo arquivo. Depois, defina o nome do experimento e selecione a instância de computação que será usada para executar o AutoML.

Na próxima etapa, escolha a coluna-alvo (a variável que se deseja prever) e defina o tipo de tarefa, que pode ser classificação, regressão ou previsão de séries temporais. Por fim, é possível ajustar configurações adicionais, como o tempo máximo de execução, a métrica de avaliação e o método de validação. Após configurar tudo, clique em "Finalizar" para iniciar o processo automatizado de treinamento de modelos.



Fonte: Elaborada pelo autor

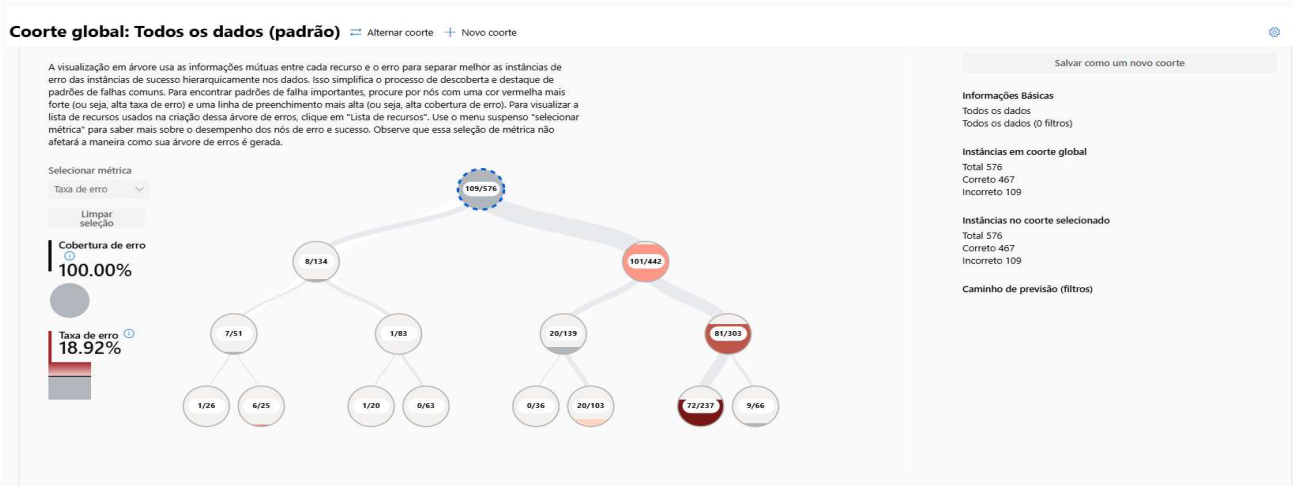
3. RESULTADO

Após a execução do processo de Machine Learning Automatizado, o Azure Machine Learning Studio identificou o modelo com melhor desempenho utilizando a técnica de Voting Ensemble, que combina os resultados de múltiplos algoritmos para obter uma previsão mais robusta. O modelo final alcançou uma AUC ponderada de 0,83374, indicando uma boa capacidade de discriminação entre as classes previstas.


A amostragem dos dados foi de 100%, garantindo que todo o conjunto foi utilizado no treinamento. Até o momento, o modelo ainda não foi registrado nem implantado, permanecendo disponível apenas

para análise interna e validação. Os detalhes completos do ensemble e outras métricas de desempenho estão acessíveis na plataforma para avaliação mais aprofundada.


3.1 Mapa de árvore



3.2 Visão Geral do Modelo



3.3 Matriz de confusão



3.4 Análise de Dados


Análise de dados

Modo de exibição de tabela Exibição de gráfico

Exiba o conjunto de dados em um formato de tabela para todos os recursos e linhas.

Index	TrueY	PredictedY	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI
>	Previsões corretas (467)							
>	Previsões incorretas (109)							
7	1	0	4	125	80	0	0	32.29999923706055
17	1	0	10	115	0	0	0	0
20	1	0	6	125	78	31	0	27.600000381469727
24	0	1	7	150	66	42	342	34.70000076295945
26	1	0	3	107	62	13	48	22.899999618530273
33	0	1	1	138	82	0	0	40.099999474121094
36	0	1	0	161	50	0	0	21.899999618530273
40	0	1	3	180	64	34	70	34

3.5 Importância do Recurso



3.6 Visão Geral do Modelo



3.7 Métricas do melhor modelo

✓ (24) silly_vase_j94nyp3r

